


$$\Theta_{t+1} = \Theta_t - \eta g(B, \Theta)$$

SGD:

$$\Theta_{t+1} = \Theta_t - \eta \nabla_{\Theta} \mathcal{L}(B, \Theta)$$



# Batch normalization


## Пакетная нормализация

$$z^{(l)} = \Theta h^{(l-1)}$$

$$z^{*(l)} = \frac{z - \mu_B(z)}{\sigma_B(z)}$$

$$\mu(z^*) = 0$$

$$\sigma(z^*) = 1$$



$$\mu_t^* = \mu_{t-1}^* \beta + \frac{1}{B} \sum z$$

$$\mu_t^* = \frac{1}{B} \sum z$$

$$\sigma_t^* = \sigma_{t-1}^* \alpha + \sigma_B(z)$$

$$z^* = \frac{z - \mu_t^*}{\sigma_t^* + \epsilon} \cdot \gamma + \xi$$

$$\begin{aligned} \gamma &= 1 \\ \xi &= 0 \end{aligned}$$


П/е обучения


① оптимизируются  $\gamma, \xi$

② „накапливаются“  $\mu^*, \sigma^*$

При вычислениях:  $\mu^*, \sigma^*, \gamma^*$  - не меняются

$L(\theta, B)$





Целостное дополнение данных  
Data augmentation

i.i.d.